

Лабораторная работа №3

«Статистические гипотезы»

Выполнил: Николай Окуньков, 18ПИ-2.

Цель работы: проверка статистических гипотез с использованием встроенных в базовую версию пакета R функций, а также некоторого ряда критериев.

Теоретическая часть:

Непрерывное равномерное распределение – распределение случайной вещественной величины, принимающей значения, принадлежащие некоторому промежутку конечной длины. Характеризуется тем, что плотность вероятности на этом промежутке почти везде постоянна.

Критерий однородности Смирнова – используется для проверки гипотезы о принадлежности двух независимых выборок одному закону распределения, то есть о том, что два эмпирических распределения соответствуют одному и тому же закону.

Критерий Колмогорова-Смирнова

$$\lambda = \sqrt{\frac{n_1 n_2}{n_1 + n_2}} \sup |F_{\Sigma 1}(x_i) - F_{\Sigma 2}(x_i)|$$

Критерий Колмогорова

$$\lambda = \sqrt{n} \sup |F_{\Sigma}(x_i) - F_T(x_i)|$$

Критерий согласия Колмогорова – используется для проверки гипотезы о принадлежности выборки некоторому закону распределения, то есть проверки того, что эмпирическое распределение соответствует предполагаемой модели.

Распределение Стьюдента – это однопараметрическое семейство абсолютно непрерывных распределений:

- Одновыборочный t-критерий – один из вариантов критерия Стьюдента, служащий для проверки нулевой гипотезы о равенстве среднего значения генеральной совокупности, из которой была взята выборка, некоторому известному значению. В общем виде проверка этой гипотезы выполняется при помощи t-критерия, рассчитывающийся как отношение разницы между выборочным средним и известным значением к стандартной ошибке выборочного среднего. Исходя из свойств t-распределения, рассчитанное значение критерия можно интерпретировать таким образом: если данное значение попадает в область отклонения нулевой гипотезы, то мы вправе отклонить проверяемую нулевую гипотезу. Область отклонения нулевой гипотезы для критерия Стьюдента определяется заранее принятым уровнем значимости и числом степеней свободы:

$$T_S = \frac{\bar{x} - a}{\hat{s}_x} \sqrt{n}$$

- Двухвыборочный t-критерий – при сравнении двух выборок проверяемая нулевая гипотеза состоит в том, что обе эти выборки происходят из нормально распределенных генеральных совокупностей с одинаковыми

средними значениями. Данные генеральные средние оценивают при помощи выборочных средних значений. В знаменателе приведенной формулы находится стандартная ошибка разницы между выборочными средними.

$$T_s = (\bar{x} - \bar{y}) \sqrt{\frac{mn(m+n-2)}{(m+n)((m-1)\hat{s}_x^2 + (n-1)\hat{s}_y^2)}$$

Значение p-value – вероятность получить для данной вероятностной модели распределения значений случайной величины такое же или более экстремальное значение статистики (среднего арифметического, медианы и др.), по сравнению с ранее наблюдаемым, при условии, что нулевая гипотеза верна.

Выборочное среднее – приближение теоретического среднего распределения, которое основывается на выборке из него.

Экспоненциальное распределение – описывает интервалы времени между независимыми событиями, которые происходят со средней интенсивностью. Количество наступлений такого события за некоторый отрезок времени описывается дискретным распределением Пуассона:

$$P_n(m) \approx \frac{\lambda^m}{m!} e^{-\lambda}$$

Критерий согласия Пирсона – непараметрический метод, позволяющий оценить значимость различий между фактическим (выявленным в результате исследования) количеством исходов или качественных характеристик выборки, попадающих в каждую категорию, и теоретическим количеством, которое можно ожидать в изучаемых группах при справедливости нулевой гипотезы:

$$\chi^2(k-1) = \sum_{i=1}^k \frac{n}{p_i} \left(\frac{n_i}{n} - p_i \right)^2$$

где n_i – число повторений в выборке числа x_i ; p_i – теоретическая вероятность появления числа x_i ; n – объём выборки; $k \leq n$.

Уровень значимости статистического теста – это допустимая для данной задачи вероятность ошибки первого рода, то есть вероятность отклонить нулевую гипотезу, когда на самом деле она верна.

Используемые в данной работе функции:

lines(), **mean(x)**, **plot()**, **seq(from, to, by =)**, **runif()**, **ks.test()**, **sd()**, **t.test()**, **sapply()**, **abline()**, **cut()**, **hist()**, **diff()**, **rexp()**, **chisq.test()**, **rnorm()**, **sort(x)**:

lines() – функция служит для создания линий на графике;

lines(x, col = , lwd =)

(Параметры: **x** – значения; **col** – цвет; **lwd** – толщина линии.)

mean(x) – функция, находящая среднее арифметическое элементов объекта **x**;

plot() – функция, служащая для построения графиков;

(Параметры: **x**, **y** – координаты точек на графике; **type** – указывает на тип графика (в данной работе используется тип “l”, lines); **xlab** – заголовок для оси **x**; **ylab** – заголовок для оси **y**; **main** – общее название графика.)

seq(from, to, by =) – функция, генерирующая последовательность чисел от **from** до **to** с шагом **by**;

runif() – функция для равномерного распределения;

runif(n, min = , max =)

(Параметры: **n** – объем выборки; **min** и **max** – нижний и верхний пределы распределения, которые должны быть представлены в виде целых чисел.)

ks.test() – функция для выполнения тестов Колмогорова-Смирнова. Возвращает значения статистики Колмогорова-Смирнова и строку с описанием гипотезы;

ks.test(x, y, ..., alternative = c(“two.sided”, “less”, “greater”), exact = NULL)

(Параметры: **x** – вектор, содержащий выборку; **y** – вектор, содержащий вторую выборку, или символьная строка с именем распределения; ... – параметры распределения; **alternative** – символьный аргумент, обозначающий тип альтернативной гипотезы (принимает одно из значений: “two.sided” (по умолчанию), “less” или “greater”); **exact** – **NULL** или логическое значение, обозначающее требуется ли точное вычисление **p-value** (не используется, если **alternative** = “less” или **alternative** = “ greater ”).)

sd() – функция для вычисления стандартного отклонения значений в **x**;

sd(x, na.rm = FALSE)

(Параметры: **x** – числовой вектор; **na.rm** – логический аргумент, указывающий на то, нужно ли исключать пропущенные значения.)

t.test() – функция, выполняющая тест Стьюдента;

t.test(x, y=NULL, alternative = c("two.sided", "less", "greater"), conf.level = 0.95, mu=NULL, paired= FALSE, var.equal=FALSE)

(Параметры: **t.test(formula, data, subset, na.action)**, где **x**, **y** – числовые векторы, первой и второй выборок; **alternative** – альтернативная гипотез (может быть одна из “two sided” (по умолчанию) – двусторонняя критическая область, “greater” – правосторонняя критическая область или “less” – левосторонняя критическая область); **conf.level** – доверительная вероятность для возвращаемого доверительного интервала; **paired** – признак парного теста, проверяется гипотеза для **x** и **y**, оба вектора должны иметь одну и ту же длину; **formula** – формула вида **lhs ~ rhs** , где **lhs** - числовой вектор, **rhs** - фактор с двумя классами; **data** – матрица или таблица данных, из которых берутся данные для **formula**; **subset** – вектор, определяющий используемое подмножество наблюдений; **na.action** – функция, которая вызывается, как только в данных встретилось значение **NA**; **var.equal** – логическая переменная, указывающая, следует ли рассматривать две дисперсии как равные (если **TRUE**, то объединенная дисперсия используется для оценки дисперсии, в противном случае используется приближение Уэлча с приближенными степенями свободы).)

sapply() – функция, используемая в случаях, когда необходимо применить какую-либо функцию к каждому компоненту списка, но результат вывести в виде вектора;

sapply(x, function, simplify = , USE.NAMES =)

(Параметры: **x** – имя матрицы, массива или таблицы данных; **function** – имя применяемой функции; **simplify** – логический аргумент (нужно ли представлять выводимый результат в виде матрицы (**TRUE**) или вектора; **USE.NAMES** – логический аргумент (если данный аргумент принимает значение **TRUE** и **x** символьного типа, то в качестве названий для вывода используется **x**).)

abline() – функция добавляет одну или несколько прямых линий через текущий график;

abline(h = , v =)

(Параметры: **h** – значение для горизонтальной линии; **v** – значение для вертикальной линии.)

cut() – функция делит вектор на равные интервалы;

cut(x = , breaks =)

(Параметры: **x** – числовой вектор; **breaks** – либо количество интервалов, либо вектор точек, по которым нужно делить вектор **x**.)

hist() – функция для создания гистограмм частот значений переменной **x**;

hist(x, breaks =)

(Параметры: **x** – переменная; **breaks** – количество столбцов.)

diff() – функция для вычисления различий между всеми последовательными значениями вектора;

diff(x, lag = , differences =)

(Параметры: **x** – вектор значений; **lag** – указывает задержку; **differences** - позволяет указать порядок различий.)

rexp() – функция экспоненциального распределения;

rexp(N, rate =)

(Параметры: **N** – объем выборки; **rate** – параметр λ .)

chisq.test() – функция критерия согласия Пирсона;

chisq.test(x, y = NULL, p = rep(1/length(x), length(x)), rescale.p = FALSE)

(Параметры: **x** – вектор или матрица; **y** – вектор (игнорируется, если **x** матрица); **p** – вектор, содержащий вероятности (должен иметь такую же длину, что и **x**); **rescale.p** – логическое значение (если **TRUE**, то **p** при необходимости нормируется так, чтобы сумма его компонент была равна 1.)

rnorm() – функция для случайной генерации совокупностей нормально распределенных чисел;

rnorm(n, mean = , sd =)

(Параметры: **n** – количество элементов выборки; **mean** – математическое ожидание; **sd** – среднеквадратическое отклонение.)

sort(x) – функция для сортировки элементов объекта **x** по возрастанию.

Ход работы:

Задание 1:

Для двух частей реализации выборки объема $N=100$ случайной величины, распределенной по равномерному закону в интервале $[0, 1]$, с помощью критерия однородности Смирнова на уровне значимости $\alpha = 0.05$ проверить нулевую гипотезу $H_0: \bar{x} = \bar{y}$, при альтернативной H_1 : а) $\bar{x} \neq \bar{y}$, б) $\bar{x} < \bar{y}$, в) $\bar{x} > \bar{y}$.

z – выборка объемом 100; x – часть выборки z объемом 49, y – часть выборки z объемом 51.

```
N <- 100 # кол-во элементов в выборке
sign.lvl <- 0.05 # уровень значимости

# Создадим выбоки и разделим их на две части по 49 и 51 элементам
z <- runif(N, min = 0, max = 1); z # создаем выборку
x <- z[1:49]; x
y <- z[50:100]; y

# Проверка нулевой гипотезы с помощью критерия Колмагорова-Смирнова
h1.1 <- ks.test(X, Y, alternative = "two.sided"); h1.1
h1.2 <- ks.test(X, Y, alternative = "less"); h1.2
h1.3 <- ks.test(X, Y, alternative = "greater"); h1.3

# Проверка
h1.1$a$p.value > sign.lvl
h1.2$a$p.value > sign.lvl
h1.3$a$p.value > sign.lvl

# Очиска памяти
rm(list = ls()); gc()
```

Результат:

```
> # Проверка нулевой гипотезы с помощью критерия Колмагорова-Смирнова
> h1.1 <- ks.test(x, y, alternative = "two.sided"); h1.1
```

Two-sample Kolmogorov-Smirnov test

```
data: x and y
D = 0.17447, p-value = 0.3664
alternative hypothesis: two-sided
```

```
> h1.2 <- ks.test(x, y, alternative = "less"); h1.2
```

Two-sample Kolmogorov-Smirnov test

```
data: x and y
D^- = 0.17447, p-value = 0.2184
alternative hypothesis: the CDF of x lies below that of y
```

```
> h1.3 <- ks.test(x, y, alternative = "greater"); h1.3
```

Two-sample Kolmogorov-Smirnov test

```
data: x and y
D^+ = 0.067627, p-value = 0.7957
alternative hypothesis: the CDF of x lies above that of y
```

```
> # Проверка
> h1.1$a$p.value > sign.lvl
[1] TRUE
> h1.2$a$p.value > sign.lvl
[1] TRUE
> h1.3$a$p.value > sign.lvl
[1] TRUE
```

Задание 2:

Для реализации выборки объемом 100 из генеральной совокупности случайной величины, распределенной по равномерному закону в интервале [2, 3], проанализировать с помощью одновыборочного критерия Стьюдента зависимости для достигаемого уровня значимости α от значения параметра $a \in [\bar{x} - \frac{s}{2}; \bar{x} + \frac{s}{2}]$ для нулевой гипотезы $H_0: \bar{x} = a$ при альтернативной H_1 : а) $\bar{x} \neq a$, б) $\bar{x} < a$, в) $\bar{x} > a$. Построить графики (на одном рисунке для разных альтернативных гипотез) зависимости величины p-value от величины параметра a . На графике также построить границу принятия нулевой гипотезы для заданного уровня значимости $\alpha = 0,05$.

```
supplytTest <- function(array, X, alt){
  res <- sapply(array, function(param) t.test(X, mu = param, alternative = alt)[[3]])
}

N <- 100 # кол-во элементов в выборке
sign.lvl <- 0.05 # уровень значимости

z <- runif(N, min = 2, max = 3); z # создаем выборку
x <- mean(z); x # выборочная средняя
s <- sd(z); s # стандартное отклонение

# Найдем параметры a
a <- seq(x-s/2, x+s/2, length = N); a


n_eq <- supplytTest(a, z, "two.sided"); n_eq
l <- supplytTest(a, z, "less"); l
g <- supplytTest(a, z, "greater"); g

plot(a, n_eq, type = "l", col = "black",
      xlab = "a",
      ylab = "p-value")
lines(a, l, type = "l", col = "red")
lines(a, g, type = "l", col = "green")
abline(h = c(0, sign.lvl), lty = 3)

# Очистка памяти
rm(list = ls()); gc()
```

Результат:

```
> # Найдем параметры a
> a <- seq(x-s/2, x+s/2, length = N); a
[1] 2.314803 2.317706 2.320608 2.323511 2.326414 2.329316 2.332219 2.335121 2.338024 2.340927 2.343829 2.346732 2.349635 2.352537 2.355440 2.358342 2.361245 2.364148 2.367050 2.369953 2.372855
[22] 2.375758 2.378661 2.381563 2.384466 2.387369 2.390271 2.393174 2.396076 2.398979 2.401882 2.404784 2.407687 2.410590 2.413492 2.416395 2.419297 2.422200 2.425103 2.428005 2.430908 2.433811
[43] 2.436713 2.439616 2.442518 2.445421 2.448324 2.451226 2.454129 2.457031 2.459934 2.462837 2.465739 2.468642 2.471545 2.474447 2.477350 2.480252 2.483155 2.486058 2.488960 2.491863 2.494766
[64] 2.497668 2.500571 2.503473 2.506376 2.509279 2.512181 2.515084 2.517987 2.520889 2.523792 2.526694 2.529597 2.532500 2.535402 2.538305 2.541207 2.544110 2.547013 2.549915 2.552818 2.555721
[85] 2.558623 2.561526 2.564428 2.567331 2.570234 2.573136 2.576039 2.578942 2.581844 2.584747 2.587649 2.590552 2.593455 2.596357 2.599260 2.602163
> n_eq <- supplytTest(a, z, "two.sided"); n_eq
[1] 2.481396e-06 3.760572e-06 5.672954e-06 8.517341e-06 1.272565e-05 1.891817e-05 2.797970e-05 4.116362e-05 6.023274e-05 8.764812e-05 1.268195e-04 1.824340e-04 2.608829e-04 3.708085e-04
[15] 5.237965e-04 7.352421e-04 1.025415e-03 1.420752e-03 1.955397e-03 2.673009e-03 3.628827e-03 4.891996e-03 6.548097e-03 8.701827e-03 1.147972e-02 1.503278e-02 1.953882e-02 2.520430e-02
[29] 3.226546e-02 4.098832e-02 5.166743e-02 6.462296e-02 8.019596e-02 9.874155e-02 1.206200e-01 1.461858e-01 1.757748e-01 2.096895e-01 2.481844e-01 2.914496e-01 3.395964e-01 3.926431e-01
[43] 4.505044e-01 5.129835e-01 5.797680e-01 6.504314e-01 7.244389e-01 8.011587e-01 8.798777e-01 9.598217e-01 1.039821e-01 1.120620e-01 1.206200e-01 1.291455e-01 1.381956e-01 1.472966e-01 1.566743e-01
[57] 1.529835e-01 1.613273e-01 1.696785e-01 1.780234e-01 1.863683e-01 1.947132e-01 2.030581e-01 2.114030e-01 2.197479e-01 2.280928e-01 2.364377e-01 2.447826e-01 2.531275e-01 2.614724e-01 2.698173e-01
[71] 2.781622e-01 2.865071e-01 2.948520e-01 3.031969e-01 3.115418e-01 3.198867e-01 3.282316e-01 3.365765e-01 3.449214e-01 3.532663e-01 3.616112e-01 3.699561e-01 3.783010e-01 3.866459e-01 3.949908e-01
[85] 4.033357e-01 4.116806e-01 4.200255e-01 4.283704e-01 4.367153e-01 4.450602e-01 4.534051e-01 4.617500e-01 4.700949e-01 4.784398e-01 4.867847e-01 4.951296e-01 5.034745e-01 5.118194e-01 5.201643e-01
[99] 5.285092e-01 5.368541e-01 5.451990e-01 5.535439e-01 5.618888e-01 5.702337e-01 5.785786e-01 5.869235e-01 5.952684e-01 6.036133e-01 6.119582e-01 6.203031e-01 6.286480e-01 6.369929e-01 6.453378e-01
> l <- supplytTest(a, z, "less"); l
[1] 9.999988e-01 9.999988e-01 9.999972e-01 9.999957e-01 9.999936e-01 9.999905e-01 9.999860e-01 9.999794e-01 9.999699e-01 9.999562e-01 9.999366e-01 9.999088e-01 9.998696e-01 9.998146e-01
[15] 9.997381e-01 9.996324e-01 9.994873e-01 9.992896e-01 9.990223e-01 9.986635e-01 9.981856e-01 9.975540e-01 9.967260e-01 9.956491e-01 9.942601e-01 9.924836e-01 9.902306e-01 9.873978e-01
[29] 9.838673e-01 9.795058e-01 9.741663e-01 9.676885e-01 9.599020e-01 9.506292e-01 9.396900e-01 9.269071e-01 9.121126e-01 8.951552e-01 8.759078e-01 8.542752e-01 8.302018e-01 8.036785e-01
[43] 7.747478e-01 7.435082e-01 7.101160e-01 6.747843e-01 6.377806e-01 5.994207e-01 5.600612e-01 5.200892e-01 4.799108e-01 4.399388e-01 4.005793e-01 3.622194e-01 3.252157e-01 2.898840e-01
[57] 2.564918e-01 2.252522e-01 1.963215e-01 1.697982e-01 1.457248e-01 1.240922e-01 1.048448e-01 8.788739e-02 7.309292e-02 6.031001e-02 4.937078e-02 4.009798e-02 3.231148e-02 2.583371e-02
[71] 2.049416e-02 1.613273e-02 1.260215e-02 9.769408e-03 7.516390e-03 5.739860e-03 4.350913e-03 3.274048e-03 2.445998e-03 1.814413e-03 1.336504e-03 9.776985e-04 7.103758e-04 5.127074e-04
[85] 3.676211e-04 2.618983e-04 1.854042e-04 1.304415e-04 9.121702e-05 6.340975e-05 4.382406e-05 3.011637e-05 2.058181e-05 1.398985e-05 9.459086e-06 6.362827e-06 4.258671e-06 2.836477e-06
[99] 1.880286e-06 1.240698e-06
> g <- supplytTest(a, z, "greater"); g
[1] 1.240698e-06 1.880286e-06 2.836477e-06 4.258671e-06 6.362827e-06 9.459086e-06 1.398985e-05 2.058181e-05 3.011637e-05 4.382406e-05 6.340975e-05 9.121702e-05 1.304415e-04 1.854042e-04
[15] 2.618983e-04 3.676211e-04 5.127074e-04 7.103758e-04 9.776985e-04 1.336504e-03 1.814413e-03 2.445998e-03 3.274048e-03 4.350913e-03 5.739860e-03 7.516390e-03 9.769408e-03 1.260215e-02
[29] 1.613273e-02 2.049416e-02 2.583371e-02 3.231148e-02 4.009798e-02 4.937078e-02 6.031001e-02 7.309292e-02 8.788739e-02 1.048448e-01 1.240922e-01 1.457248e-01 1.697982e-01 1.963215e-01
[43] 2.252522e-01 2.564918e-01 2.898840e-01 3.252157e-01 3.622194e-01 4.005793e-01 4.399388e-01 4.799108e-01 5.200892e-01 5.600612e-01 5.994207e-01 6.377806e-01 6.747843e-01 7.101160e-01
[57] 7.435082e-01 7.747478e-01 8.036785e-01 8.302018e-01 8.542752e-01 8.759078e-01 8.951552e-01 9.121126e-01 9.269071e-01 9.396900e-01 9.506292e-01 9.599020e-01 9.676885e-01 9.741663e-01
[71] 9.795058e-01 9.838673e-01 9.873978e-01 9.902306e-01 9.924836e-01 9.942601e-01 9.956491e-01 9.967260e-01 9.975540e-01 9.981856e-01 9.986635e-01 9.990223e-01 9.992896e-01 9.994873e-01
[85] 9.996324e-01 9.997381e-01 9.998146e-01 9.998696e-01 9.999088e-01 9.999366e-01 9.999562e-01 9.999699e-01 9.999794e-01 9.999860e-01 9.999905e-01 9.999936e-01 9.999957e-01 9.999972e-01
[99] 9.999988e-01 9.999988e-01
```



Задание 3:

Для выборки объемом 200 из генеральной совокупности случайной величины X , распределенной по экспоненциальному закону с параметром $\lambda = 0,2$, проверить нулевую гипотезу $H_0: F(x) = F_0(x, \lambda_{\text{оц}})$ при альтернативной $H_1: F(x) \neq F_0(x, \lambda_{\text{оц}})$ по критерию согласия Пирсона на уровне значимости $\alpha = 0,05$.

Здесь $F_0(x, \lambda_{\text{оц}})$ – функция плотности экспоненциального закона распределения с параметром $\lambda_{\text{оц}}$. $\lambda_{\text{оц}}$ – оценка параметра λ , полученная по данным выборки.

```
l <- 0.2 # параметр для экспоненциальному распределению
N <- 200 # кол-во элементов в выборке
sign.lvl <- 0.05 # уровень значимости

x <- rexp(N, l); x # создаем выборку
breaks <- c(-Inf, 1, 2, 3, 4, 5, 10, 15, 20, 25, Inf)
table <- table(cut(x, breaks = breaks)); table
p <- diff(pexp(breaks, l)); p; sum(p)

# Проверка гипотезы с помощью критерия Пирсона
h <- chisq.test(x = table, p = p); h$p.value
h$p.value > sign.lvl

# Очистка памяти
rm(list = ls()); gc()
```


Результат:

```
> x <- rnorm(N, l); x # создаем выборку
[1] 3.37887516 3.85023059 2.94606813 2.40141606 1.74671718 5.27049110 6.70707982 2.78822849 3.45937709
[10] 16.67060722 4.09584624 5.19307471 1.49502680 1.97093744 0.95855523 2.23070199 2.79467698 7.53803069
[19] 13.02063658 1.32219192 3.88168468 1.59423923 2.70178927 3.93379483 3.32946564 1.90054314 0.10366605
[28] 5.20344672 0.88413209 3.04404825 17.56339930 10.74026530 0.01713163 9.14821209 1.10750918 6.67225906
[37] 0.23488562 7.60480411 1.36635289 7.40976433 1.31819280 0.33683652 8.32941459 0.13481212 7.38995535
[46] 0.61791211 0.36348477 16.04819458 6.54552861 18.32188281 9.44982543 2.51934949 4.24754291 1.23083911
[55] 24.55113851 4.95086408 6.04736631 1.61763008 5.27876524 10.38409331 8.24688160 7.71207014 11.99483543
[64] 2.92720058 11.54831156 2.40364161 6.07034032 4.36878469 0.22725833 3.61160804 14.33644757 5.12194998
[73] 4.31343072 1.65661436 6.68500313 1.86344205 5.18433971 1.61701376 3.48148650 7.65791134 15.97060531
[82] 6.73281220 4.26674736 3.12117946 5.06065459 2.38404528 2.58056240 6.33595322 13.34908617 2.32591292
[91] 2.67234359 0.92412221 5.82914639 1.39359034 10.41672447 34.92591255 13.10272331 1.55299720 10.89731902
[100] 4.01812985 0.49273800 5.30243624 2.01276286 7.14640015 2.43905327 6.40997024 0.83266041 20.17365615
[109] 0.72116859 3.67339891 1.14174420 2.53767584 1.14241308 3.22120566 0.96424605 0.01770892 3.43383296
[118] 0.05497028 0.52766674 5.47820921 1.13781898 1.10230825 9.07717034 0.11583849 1.19158754 2.87201825
[127] 1.07481854 2.92341311 2.08509040 2.22102196 1.51126114 1.84460098 6.19786058 16.14336558 6.02120361
[136] 4.39286418 7.22956290 2.30957958 0.35205933 0.56200672 2.50521005 2.32696648 3.34889917 0.30628021
[145] 3.59212644 1.12581236 0.28218313 0.18785218 3.01449647 0.95323467 4.23065231 1.87216529 2.91568242
[154] 0.19008814 1.92556271 4.61087671 20.14373566 5.32196340 6.91783857 4.62619880 1.80544284 13.54621465
[163] 12.04325794 21.87206814 12.68905031 5.94715589 0.04458074 8.19900861 5.18417354 2.81614244 0.34107148
[172] 2.52843033 5.29276159 7.31032945 12.09217791 1.63528486 8.28450826 7.81907582 10.52021296 4.15017742
[181] 3.47341917 3.82889126 1.97244039 1.83520118 0.38429693 0.72742032 2.63519592 0.94879422 6.27862568
[190] 5.91399326 7.91438612 2.62603532 5.33261595 0.79641127 5.52961354 0.85730583 0.15206641 6.94881441
[199] 11.73618524 0.42413367

> breaks <- c(-Inf, 1, 2, 3, 4, 5, 10, 15, 20, 25, Inf)
> table <- table(cut(x, breaks = breaks)); table

(-Inf,1] (1,2] (2,3] (3,4] (4,5] (5,10] (10,15] (15,20] (20,25] (25, Inf]
      35      31      28      18      12      49      16       6       4       1

> p <- diff(pexp(breaks, l)); p; sum(p)
[1] 0.181269247 0.148410707 0.121508410 0.099482672 0.081449523 0.232544158 0.085548215 0.031471429 0.011577692
[10] 0.006737947
[1] 1
> # Проверка гипотезы с помощью критерия Пирсона
> h <- chisq.test(x = table, p = p); h$p.value
[1] 0.9406451
> h$p.value > sign.lvl
[1] TRUE
```

Задание 4:

Для центрированной выборки объемом 100 из генеральной совокупности случайной величины X , распределенной по нормальному закону с $a = 8$ и $sd = 2$, с помощью критерия согласия Колмогорова проанализировать зависимость достигнутого уровня значимости α от числа степеней свободы $m \in [2, 20]$ (построить график и проанализировать его) для нулевой гипотезы $H_0: F(x) = F_0(x, m)$ при альтернативной $H_1: F(x) \neq F_0(x, m)$, где $F_0(x, m)$ – теоретическая функция распределения Стюдента с заданным числом степеней свободы m .

```
sapplyksTest <- function(fdegrees, x){
  sapply(fdegrees, function(param) ks.test(x, "pt", param) [[2]])
}

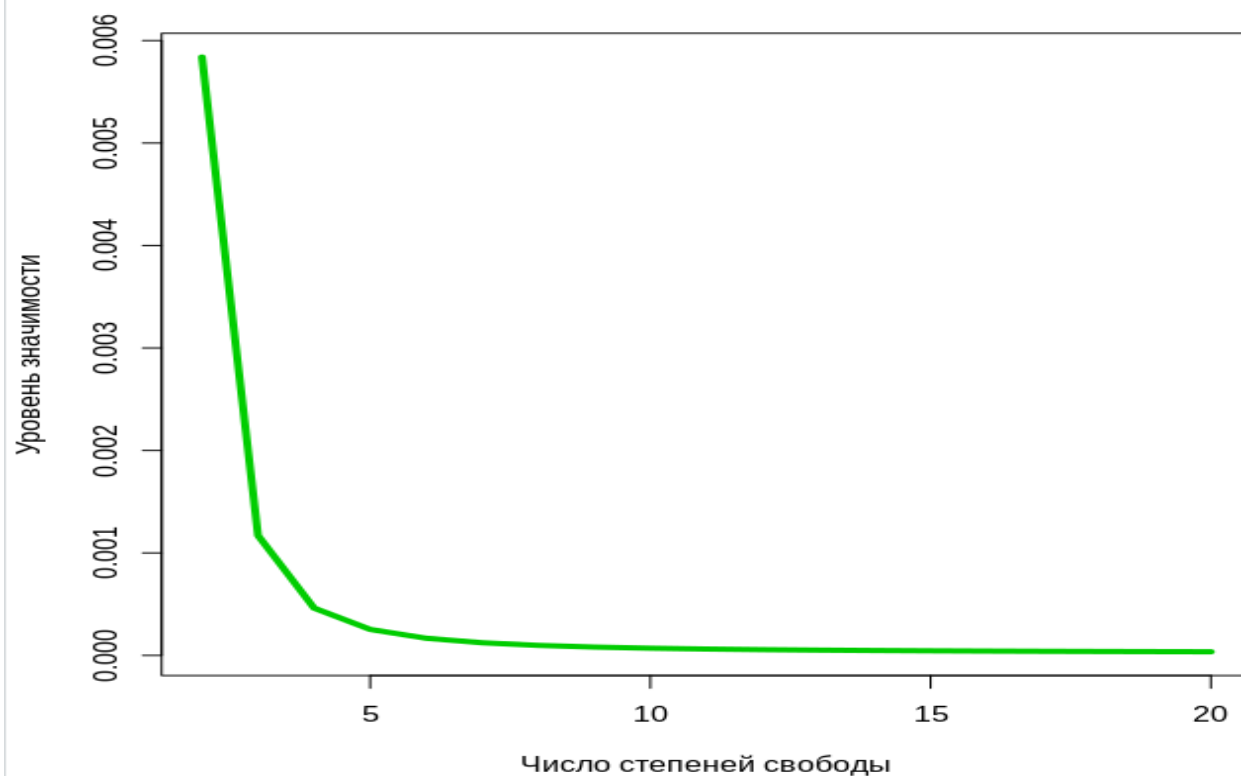
N <- 100 # Кол-во элементов в выборке
mean <- 8 # Мат. ожидание
sd <- 2 # Стандартное отклонение
fdegrees <- c(2:20) # Число степеней свободы

# Создаем выборку нормального распределения
x <- rnorm(N, mean = mean, sd = sd); x

# Центрируем выборку
x <- sort(x - mean(x)); x

lvls <- sapplyksTest(fdegrees, x)
plot(fdegrees, lvls, type = "l", col = 3, lwd = 4,
     xlab = "Число степеней свободы",
     ylab = "Уровень значимости")
```


Результат:



Вывод

В ходе работы мной были проверены статистические гипотезы на разных наборах данных (выборках), что помогло мне усвоить теоретический материал, используемый в данной работе, узнать о новых функциях пакета R и ознакомиться с механизмом их работы.